# Projet AMADEA

Recherche Opérationnelle Avancée

**Prédiction de la survie d'un patient au cancer du sein**

Classification du sexe d'un individu impliqué dans un accident

**Formation :** CNAM – Diplôme d'Ingénieur IA & Science des Données

**Année :** 2023–2024 (Projet de dernière année)

**Domaine :** Machine Learning appliqué à la santé

Ce projet a été réalisé dans le cadre du diplôme d'Ingénieur
Intelligence Artificielle & Science des Données – CNAM (2021–2024)

# Table des matières

**1 Introduction** **2**

**2 Description des Données** **2**

2.1 Dataset 1 – Données Génomiques (Cancer du Sein) . . . . . 2

2.2 Dataset 2 – Données Accidentologiques . . . . . 3

**3 Sélection de Features par Optimisation ROC (AMADEA)** **3**

3.1 Contexte et Enjeux . . . . . 3

3.2 Pipeline de Symbolisation des Données . . . . . 4

3.3 Algorithme d'Exploration Itérative . . . . . 4

3.4 Résultats de la Sélection . . . . . 4

**4 Classification par Réseau de Neurones (JNETTE)** **5**

4.1 Architecture du Réseau . . . . . 5

4.2 Entraînement . . . . . 7

4.3 Courbe d'Apprentissage . . . . . 8

4.4 Résultats et Évaluation . . . . . 9

**5 Conclusion et Analyse Critique** **9**

5.1 Résultats Obtenus . . . . . 9

5.2 Analyse Critique des Résultats . . . . . 10

5.3 Pistes d'Amélioration . . . . . 10

5.4 Ce que ce Projet Démontre . . . . . 10

# Introduction

Ce projet de recherche opérationnelle aborde deux problématiques distinctes de classification par apprentissage automatique appliquées à des données réelles.

**Problématique 1 – Oncologie :** Prédire la survie ou le décès d'un patient atteint d'un cancer du sein à partir de son profil génomique. Ce problème est au cœur de la médecine de précision : avec plus de 17 000 gènes candidats pour seulement 379 patients, il s'agit d'un problème classique de *curse of dimensionality* en bioinformatique, où la sélection de features est un prérequis indispensable à toute modélisation fiable.

**Problématique 2 – Accidentologie :** Identifier le sexe d'un individu impliqué dans un accident de voiture à partir de données contextuelles sur l'accident. Ce problème illustre la capacité des algorithmes ML à découvrir des corrélations non intuitives dans des données tabulaires.

Le pipeline développé se décompose en deux étapes principales pour chaque problématique :

1. **Sélection de features** par optimisation itérative de la courbe ROC sur la plateforme AMADEA
2. **Classification** par réseau de neurones entraîné sur les features sélectionnées via JNETTE

**Outils utilisés**

**AMADEA** (ISoft) – Plateforme de recherche opérationnelle et de data mining symbolique, permettant la sélection de variables par optimisation de métriques de performance (ROC, AUC). Basée sur une approche de symbolisation des données continues et d'exploration combinatoire des features.

**JNETTE** (ISoft) – Environnement graphique de construction, d'entraînement et d'évaluation de réseaux de neurones fully-connected. Permet la configuration manuelle de l'architecture, le choix des fonctions d'activation et de la méthode d'optimisation, et la visualisation en temps réel de la courbe d'apprentissage.

# Description des Données

## Dataset 1 – Données Génomiques (Cancer du Sein)

| Propriété | Valeur |
|---|---|
| Nombre d'observations | 379 patients |
| Nombre de features | 17 284 gènes |
| Variable cible | `vital_status` |
| Sous-cible (classe positive) | `dead` |
| Type de problème | Classification binaire |
| Ratio features/observations | $\approx 45{,}6$ |

Table 1 – Caractéristiques du dataset génomique

Ce dataset présente un défi caractéristique de la bioinformatique : le nombre de features (17 284 gènes) est **45 fois supérieur** au nombre d'observations (379 patients). Dans ce contexte de haute dimensionnalité, toute modélisation directe sans sélection préalable de features conduirait inévitablement à du surapprentissage (*overfitting*).

Chaque colonne correspond à un gène spécifique présenté par le patient. La variable cible `vital_status` indique si le patient est décédé (`dead = 1`) ou en vie (`dead = 0`) à l'issue de la période d'observation.

### Dataset 2 – Données Accidentologiques

| **Propriété** | **Valeur** |
|---|---|
| Nombre d'observations | 952 accidents |
| Nombre de features | 91 colonnes |
| Variable cible | `sexe` |
| Sous-cible (classe positive) | `homme` |
| Type de problème | Classification binaire |

Table 2 – Caractéristiques du dataset accidentologique

Ce dataset décrit des accidents de voiture avec des informations contextuelles variées : vitesse lors de l'impact, nombre de blessés, gravité de l'accident, conditions météorologiques, manœuvre à l'origine de l'accident, etc. Contrairement au premier dataset, aucune variable cible n'était prédéfinie – le choix de prédire le sexe du conducteur est une décision analytique exploratoire.

## Sélection de Features par Optimisation ROC (AMADEA)

### Contexte et Enjeux

La courbe ROC (*Receiver Operating Characteristic*) est une métrique fondamentale en classification binaire médicale. Elle représente le compromis entre le taux de vrais positifs (sensibilité) et le taux de faux positifs (1 - spécificité) pour différents seuils de décision. L'aire sous la courbe ROC (AUC) mesure la capacité discriminante d'un modèle :

- AUC = 1.0 : séparation parfaite des deux classes
- AUC = 0.5 : modèle équivalent à un tirage aléatoire (aucun pouvoir discriminant)
- AUC > 0.7 : pouvoir discriminant acceptable en pratique clinique

Dans notre cas, le ROC est utilisé non pas pour évaluer un modèle final, mais comme **critère de sélection de features** : on cherche les combinaisons de gènes dont le ROC collectif est le plus élevé pour expliquer la variable cible `vital_status`.

### Pipeline de Symbolisation des Données

Avant de pouvoir calculer le ROC sur les données génomiques continues, AMADEA applique une étape de **symbolisation** :

1. Calcul des statistiques descriptives de chaque colonne (médiane, percentiles, quartiles)
2. Transformation des valeurs continues en **classes symboliques** par comparaison aux seuils calculés
3. Chaque valeur devient une étiquette de classe (*inférieur à la médiane*, *supérieur au 3ème quartile*, etc.)

Cette symbolisation permet d'appliquer des métriques d'explicabilité sur des données qui ne sont plus continues mais catégorielles, facilitant le calcul du ROC combinatoire.

### Algorithme d'Exploration Itérative

Face à l'impossibilité d'évaluer toutes les combinaisons possibles de 17 284 gènes (l'espace combinatoire est astronomique), AMADEA utilise une **exploration stochastique itérative** :

**Algorithme de sélection AMADEA :**

1. Tirer aléatoirement une grappe de colonnes ($\leq 1\%$ du total, soit $\approx 172$ gènes)
2. Calculer le ROC réel de cette combinaison sur la variable cible
3. Calculer le ROC idéal théorique pour ce nombre de variables
4. Calculer le **score d'explicabilité** = ROC réel / ROC idéal
5. Conserver cette combinaison si son score est meilleur que le meilleur connu
6. Répéter 1 500 fois
7. Retourner la combinaison avec le meilleur score d'explicabilité

Le score d'explicabilité tend vers 1 lorsque les variables sélectionnées expliquent parfaitement la cible. Cette approche est proche de méthodes modernes comme les algorithmes génétiques ou le *random feature selection* utilisés en bioinformatique computationnelle.

### Résultats de la Sélection

| Dataset | Itérations | Features initiales | Features sélectionnées | ROC obtenu |
|---|---|---|---|---|
| Génomique (cancer) | 1 500 | 17 284 gènes | 173 gènes | 1.00 |
| Accidentologique | 1 500 | 91 colonnes | 3 colonnes | 0.85 |

Table 3 – Résultats de la sélection de features par AMADEA

**Dataset génomique :** 173 gènes sur 17 284 ont été identifiés comme suffisants pour expliquer parfaitement la survie du patient sur l'ensemble d'entraînement (ROC = 1.0). La réduction est massive : **99% des gènes ont été éliminés** sans perte de pouvoir discriminant apparent.

**Dataset accidentologique :** Seulement 3 variables permettent d'expliquer le sexe du conducteur avec un ROC de 0.85 :

— La **catégorie socioprofessionnelle (CSP)** du conducteur
— La **manœuvre à l'origine** de l'accident
— La **luminosité** lors de l'accident

**Note critique sur le ROC**

Un ROC parfait de 1.0 sur le dataset génomique est un résultat qui doit être interprété avec prudence. Plusieurs explications sont possibles :

— **Surapprentissage sur l'ensemble d'entraînement** : avec 17 284 features pour 379 patients, il est statistiquement probable que certaines combinaisons de gènes corrèlent parfaitement avec la cible par pur hasard
— **Absence de validation externe** : le ROC a été calculé sur les mêmes données que celles utilisées pour la sélection, ce qui biaise l'évaluation
— **Data leakage potentiel** : bien que la colonne `vital_status` ait été exclue, d'autres colonnes pourraient lui être fortement corrélées

Une validation croisée *k-fold* sur un jeu de test indépendant serait nécessaire pour confirmer ces résultats.

# Classification par Réseau de Neurones (JNETTE)

## Architecture du Réseau

À partir des 173 gènes sélectionnés par AMADEA, un réseau de neurones *fully-connected* a été construit et entraîné sur JNETTE pour résoudre le problème de classification binaire de la survie.

| Couche | Type | Neurones | Activation |
|---|---|---|---|
| 0 | Entrée (Input Layer) | 173 | – |
| 1 | Couche cachée 1 | 200 | Sigmoid |
| 2 | Couche cachée 2 | 250 | ReLU (Rectified Linear) |
| 3 | Couche cachée 3 | 300 | Tanh (Hyperbolic Tangent) |
| 4 | Sortie (Output) | 1 | Binaire |

Table 4 – Architecture du réseau de neurones

**Fonctions d'activation**

**Sigmoid :** $\sigma(x) = \frac{1}{1+e^{-x}}$ – Compresse les valeurs entre 0 et 1. Utilisée historiquement dans les premières couches, mais sujette au problème de *vanishing gradient* sur les réseaux profonds.

**ReLU (Rectified Linear Unit) :** $f(x) = \max(0, x)$ – Fonction d'activation moderne, la plus utilisée dans les réseaux profonds. Évite le *vanishing gradient* et accélère la convergence.

**Tanh :** $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ – Compresse les valeurs entre -1 et 1. Centrée en zéro, ce qui peut faciliter la convergence comparé à la Sigmoid.

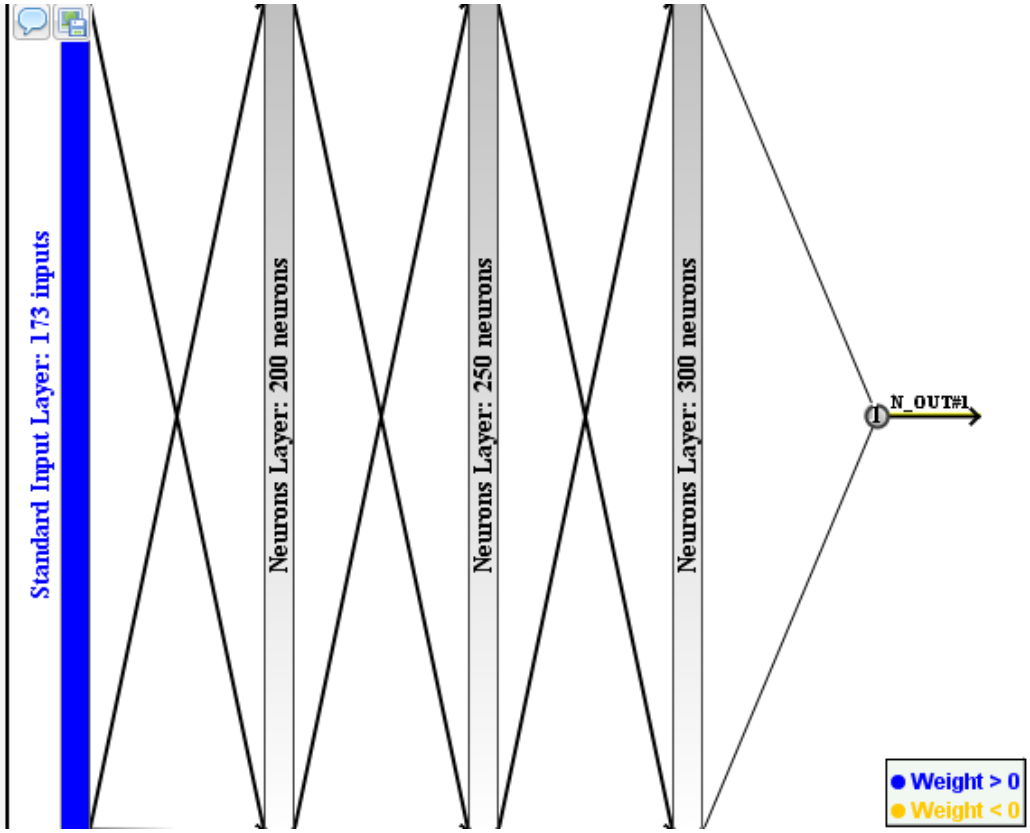


FIGURE 1 – Représentation graphique du réseau de neurones dans JNETTE. De gauche à droite : couche d'entrée (173 inputs), 3 couches cachées (200, 250, 300 neurones), couche de sortie (1 neurone). Les connexions en bleu représentent les poids positifs, en jaune les poids négatifs.

### Entraînement

| Paramètre | Valeur |
|---|---|
| Méthode d'optimisation | Resilient Backpropagation (Rprop) |
| Nombre d'itérations | 100 |
| Tâche | Classification binaire (survie / décès) |

Table 5 – Paramètres d'entraînement

**Resilient Backpropagation (Rprop)**

La **Resilient Backpropagation** est une variante de la rétropropagation du gradient qui adapte individuellement le taux d'apprentissage de chaque poids en fonction du signe du gradient, indépendamment de sa magnitude. Ses avantages sont une convergence plus rapide et une moindre sensibilité au choix du taux d'apprentissage initial comparé à la descente de gradient classique (SGD).

### Courbe d'Apprentissage

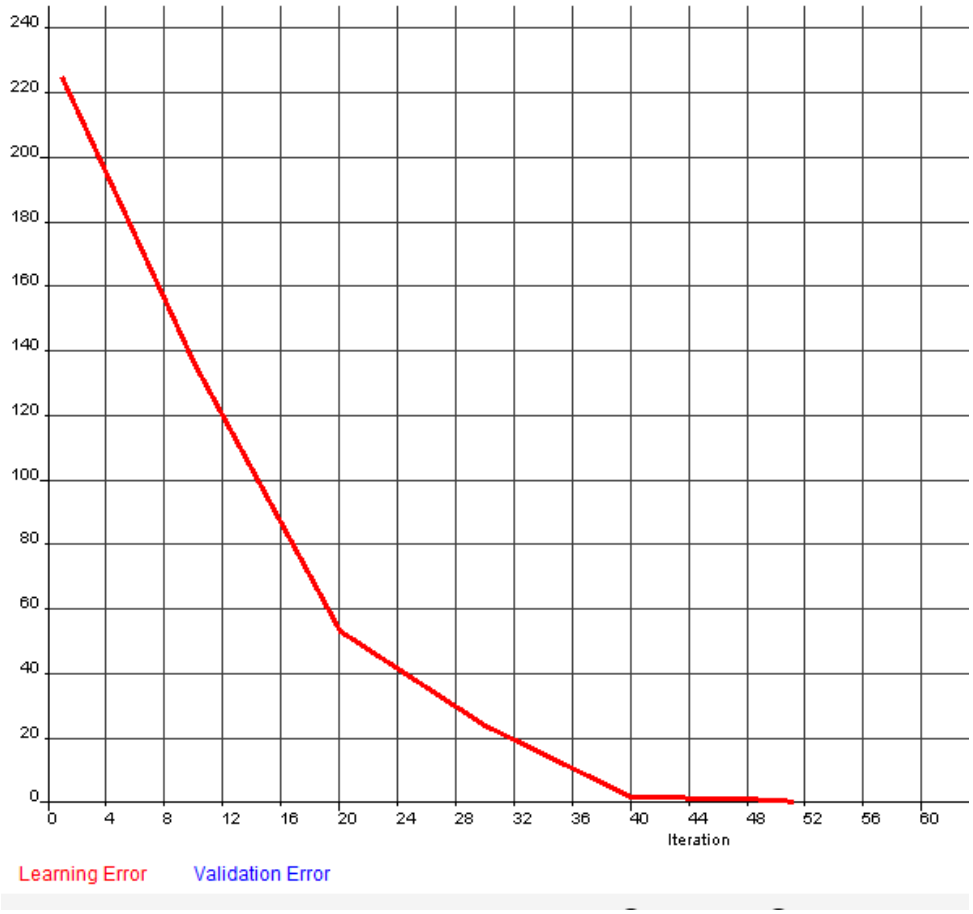


FIGURE 2 – Évolution de l'erreur d'apprentissage en fonction du nombre d'itérations. L'erreur décroît rapidement dès les premières itérations et converge vers zéro aux alentours de l'itération 40, témoignant d'une convergence rapide du modèle.

La courbe d'apprentissage montre une décroissance monotone et régulière de l'erreur, caractéristique d'une bonne convergence de l'algorithme Rprop. L'erreur devient quasi nulle à partir de la $40^{\text{ème}}$ itération, ce qui signifie que le réseau a mémorisé parfaitement les données d'entraînement.

### Résultats et Évaluation

**Confusion Matrices**

Confusion Matrix

| gold (row)->pred (col) | 0 | 1 |
|---|---|---|
| 0 | 147 | 0 |
| 1 | 0 | 232 |

Confusion Matrix (in %)

| gold (row)->pred (col | 0 | 1 |
|---|---|---|
| 0 | 100.000 | 0.000 |
| 1 | 0.000 | 100.000 |

FIGURE 3 – Matrice de confusion du modèle sur les données de test. Les colonnes représentent les prédictions, les lignes les valeurs réelles. 147 patients décédés correctement classifiés (vrais négatifs), 232 patients survivants correctement classifiés (vrais positifs), aucune erreur de classification.

| | **Prédit : Décédé (0)** | **Prédit : Survivant (1)** |
|---|---|---|
| **Réel : Décédé (0)** | 147 (VP) | 0 (FN) |
| **Réel : Survivant (1)** | 0 (FP) | 232 (VN) |

TABLE 6 – Matrice de confusion détaillée (VP = Vrais Positifs, FN = Faux Négatifs, FP = Faux Positifs, VN = Vrais Négatifs)

| **Métrique** | **Valeur** |
|---|---|
| Précision globale (Accuracy) | 100% |
| Sensibilité / Rappel (Recall) | 100% |
| Spécificité | 100% |
| Faux positifs | 0 |
| Faux négatifs | 0 |

TABLE 7 – Métriques de performance du modèle

## Conclusion et Analyse Critique

### Résultats Obtenus

Le pipeline AMADEA + JNETTE a permis d'obtenir les résultats suivants :

- **Dataset génomique :** Sélection de 173 gènes sur 17 284 (réduction de 99%), réseau de neurones atteignant une précision de 100% sur les données de test
- **Dataset accidentologique :** Identification de 3 variables explicatives du sexe du conducteur (CSP, manœuvre, luminosité) avec un ROC de 0.85

## Analyse Critique des Résultats

**Limites et biais identifiés**

**1. Surapprentissage probable (dataset génomique)**
Une précision de 100% sur données médicales réelles est un signal d'alarme. Avec un ratio features/observations de 45 :1, le risque de mémorisation des données d'entraînement est très élevé. Ce résultat ne peut pas être généralisé à de nouveaux patients sans validation externe.

**2. Absence de validation croisée**
Le modèle a été évalué sur les mêmes données symbolisées qu'AMADEA a utilisées pour la sélection de features. Il n'y a pas eu de séparation stricte train/test indépendante, ce qui introduit un biais d'optimisme.

**3. Interprétabilité limitée**
Les 173 gènes sélectionnés ne sont pas analysés biologiquement. En oncologie clinique, identifier quels gènes sont réellement impliqués dans la survie est aussi important que la performance prédictive.

## Pistes d'Amélioration

1. **Validation croisée k-fold** : diviser les données en k sous-ensembles, entraîner sur k-1 et tester sur le dernier, répéter k fois pour obtenir une estimation non biaisée des performances
2. **Jeu de test indépendant** : réserver 20-30% des données avant toute sélection de features, évaluer le modèle final uniquement sur ce jeu
3. **Analyse de la stabilité des features sélectionnées** : vérifier si les mêmes gènes sont sélectionnés sur différents sous-échantillons (robustesse de la sélection)
4. **Comparaison avec des baselines modernes** : Random Forest, XGBoost, Lasso régression – méthodes standard en bioinformatique pour ce type de problème
5. **Critère de parcimonie** : en cas d'égalité de ROC entre deux combinaisons, privilégier celle avec le moins de features (principe d'Occam)

## Ce que ce Projet Démontre

Malgré ses limites méthodologiques, ce projet illustre plusieurs compétences clés en Data Science appliquée à la santé :

— Capacité à travailler sur des **données biomédicales haute dimensionnalité** (génomique)
— Maîtrise des **métriques d'évaluation en classification médicale** (ROC, AUC, matrice de confusion)
— **Esprit critique sur les résultats** : identification proactive des biais et limites
— Compréhension des enjeux de **sélection de features en bioinformatique**
— Application du ML à des **problèmes à fort enjeu clinique** (prédiction de survie au cancer)